

딥러닝 기반의 IMU 센서 데이터를 활용한 운동 분류 및 횟수 예측 연구

최한준¹, 전민기¹, 김수현¹, 고상기¹, 정학균²

강원대학교 컴퓨터공학과¹, 버닛²

{hanjunchoi, ckawoalt, tngus98207, sangkiko}@kangwon.ac.kr, viktor@bunnit.kr

Deep learning-based workout classification and repetition counting using IMU sensor data

Han Jun Choi¹, Min Gi Jeon¹, Su-Hyeon Kim¹, Sang-Ki Ko¹, Hak-Gyun Jeong²
Department of Computer Science & Engineering, Kangwon National University¹
Bunn.IT Inc.²

요 약

웨이트 트레이닝을 통해 운동 수행능력을 성장시키기 위해서는 운동 별로 세트 수와 반복 횟수를 기록해두는 것이 중요하다. 이를 자동화하기 위해 귀에 착용하는 히어러블(hearable) 장치 내에 내장된 IMU 센서를 통해 사용자의 운동 데이터를 수집하고 이를 활용하여 운동 종목과 반복 횟수를 예측하는 딥러닝 기반의 알고리즘을 제안한다. 본 논문에서 제안하는 인공 신경망 모델은 2D 합성곱 신경망(CNN)을 활용하며 학습 성능을 극대화하기 위하여 취득된 센서 데이터의 주파수 및 내재적 특징을 고려하여 여러 시계열 데이터 증강 기법을 적용하여 학습 데이터를 증강한다. 실험을 통해 각 데이터 증강 기법이 운동 분류 예측 및 횟수 예측에 미치는 영향을 알아보고 최종적으로 모든 데이터 증강 기법이 활용되었을 때의 성능을 소개한다.

I. 서 론

평균적인 삶의 질이 높아짐에 따라 건강에 대한 관심 또한 높아지고 있으며 이에 따라 웨이트 트레이닝, 크로스핏 등의 건강 관리 운동을 수행할 때 이를 좀 더 효율적으로 할 수 있도록 도와줄 수 있는 기술의 필요성이 대두되고 있다. 예를 들면, 웨이트 트레이닝을 할 때 어떤 종목의 운동을 몇 회 수행하였는지 기록하여 점진적으로 수행 횟수 및 중량을 늘려가는 것이 중요하지만 정확한 세트수와 세트당 수행 횟수를 모두 기억하기는 어렵다. 최근에는 사용자의 운동을 기록할 수 있는 스마트폰 운동 기록 어플을 사용하면 휴식시간에 간단하게 수행일지를 기록할 수 있지만 이조차도 사용자가 일일이 세트와 횟수를 기록해야 한다는 번거로움이 있다.

본 논문에서는 이러한 문제를 해결하기 위해 운동을 하는 사용자가 가속도 및 각속도 6 축으로 구성된 히어러블 디바이스(hearable device)를 귀에 착용한 상태로 운동을 하여 센서 시계열 데이터를 수집하는 상황에서, 수집한 데이터를 통해 사용자가 어떤 운동을 몇 회 수행하였는지 예측하는 합성곱 신경망 기반 딥러닝 알고리즘을 제안한다. 본 논문에서 제안하는 기여는 다음 두 가지 있다. 1) 운동 데이터로부터 운동 종류 분류와 횟수 예측을 하는 단대단 딥러닝 모델을 제안한다. 2) 센서 시계열 데이터의 증강을 위해 잡음 주입(noise injection), 크기 조정(time warping), 자르고 붙이기(split and merge) 등 여러 시계열 데이터 증강(data augmentation) 기법들을 적용하여 인공 신경망이 효과적으로 학습할 수 있는 데이터를 생성하고 증강 기법에 따른 모델의 성능을 비교 실험하여 제안한 방법론이 모델의 학습과정에 미치는 영향을 분석하고

마지막으로 증강 기법들을 단계적으로 적용한 데이터 셋의 실험 성능을 확인한다.

II. 관련 연구

1) 시계열 데이터 문제

일정한 간격으로 측정된 시계열 데이터는 날씨, 신호, 금융 등에서 예측 또는 분류 문제로 빈번히 사용된다. 전통적으로 시계열문제는 과거의 정보를 효과적으로 사용하기 위해 순환 신경망[1]을 사용하거나, 단위 공간의 관점에서 학습하기 위해 합성곱 신경망[2]을 주로 사용한다.

2) 센서데이터 전처리 기법

센서 데이터 중 가속도 데이터는 회전 성분이 포함되어 있다. 회전 성분의 영향을 받지 않고 노이즈를 줄이는 방법이 필요하기 때문에 x, y, z 축 값을 각각 제곱하여 더한 값인 CVA[3] 값을 기존 데이터에 추가하여 추가적인 특징 벡터로 활용한다.

3) 시계열 데이터 증강 기법

기존의 데이터 증강 기법은 시계열 데이터의 주파수 및 시간 의존성(temporal dependency)과 같은 내재적 특징을 활용하지 못하기에 원도우 슬라이싱, 크기 조정, 시간 뒤틀림 등[4], 주파수(frequency) 도메인에 특화된 기법들을 사용한다. 본 논문에서는 기존의 시계열 데이터 증강 기법 중 잡음 주입, 분할, 크기 조정 기법들을 운동 시계열 데이터에 맞게 변형하여 추가적인 운동 센서데이터를 확보하여 인공 신경망의 학습이 효과적으로 이루어질 수 있도록 한다.

III. 본론

운동 센서 데이터 수집 및 전처리 과정을 소개하고 취득된 센서 데이터를 활용하여 운동 종목 및 횟수를 측정하는 딥러닝 기반 알고리즘을 소개한다.

1) 데이터 수집 및 전처리

운동 데이터를 수집하기 위해 가속도 및 각속도를 측정하는 히어러블 디바이스를 착용하여 데드리프트, 스쿼트, 시트업, 푸쉬업, 풀업 총 5 종목의 운동 센서데이터를 수집하였다. 센서데이터는 한 세트당 8 회 이하로 측정하였다. 또한 각 데이터 증강 기법에 따라 원본 데이터의 약 85 배의 데이터를 추가적으로 생성하였다.

수집된 센서 데이터는 x, y, z 축으로 이루어진 가속도 및 각속도 6 축과 각각 CVA 변환 처리한 2 축을 추가적으로 사용하여 총 8 개의 특징 벡터로 변환한다. 또한 데이터 길이의 일반화를 위해 최대 길이를 총 600(60sec * 10Hz)개의 시점으로 설정하였다.

2) 딥러닝 알고리즘

본 논문에서는 2 차원 입력 데이터를 처리하기 위해 합성곱 신경망의 구조를 갖는 딥러닝 모델을 사용한다. 모델의 입력으로 60sec * 10(Hz) * 8 의 3 차원 구조의 벡터를 사용하고, 2 차원 합성곱 연산을 통해 인코딩한다. 인코딩된 문맥 벡터는 운동 종목 분류 문제와 횟수 예측 문제를 해결하기 위해 서로 다른 두 개의 다층 퍼셉트론 신경망의 입력으로 사용하여 최종 예측 결과를 출력한다.

3) 데이터 증강 기법




그림 1. 센서 데이터 증강 기법

히어러블 기기를 통해 취득된 시계열 데이터의 증강을 위해 크게 잡음 주입, 자르고 붙이기, 크기 조정의 세 가지 기법을 사용하였다. 첫 번째로 잡음 주입은 정규분포에서 샘플링 된 값을 주어진 데이터에 더하는 방식이다. 두 번째로 분할은 운동 데이터의 횟수를 나누는 방식이다. 예를 들어 8 번 횟수의 운동 데이터를 4, 5, 6, 7 횟수로 분할한다. 또한 한 횟수 마다 분할하고 무작위로 생성한 순열을 따라 재배열한다. 마지막으로 크기 조정 방식은 특정 비율을 정하여 원본 데이터를 비율만큼 늘리거나 줄이는 방식으로 사람마다 운동을 진행하는 속도는 상이하기 때문에 크기 조정 방식을 적용한 데이터를 통해 느리고 빠른 템포의 운동 패턴을 모델이 다양하게 학습할 수 있다.

IV. 실험

전체 데이터 셋에 대한 딥러닝 모델의 운동 종목 예측 및 횟수 예측에 대한 성능을 비교한다. 또한 증강 기법에 따라 생성된 데이터셋 별로 비교 실험을 통해 성능을 비교하여 증강된 데이터가 인공지능망의 학습에 미치는 영향에 대해 분석한다. 운동 분류에 대한 성능은 F1 score 을 사용하였고 횟수 예측에 대한 성능은 MSE 를 평가지표로 사용하였다.

표 1. 개별 데이터 증강 기법에 따른 실험 성능

활용 데이터	F1 score	MSE
원본 데이터	84.2%	0.6460
원본 + 자르고 붙이기	87.0%	0.3699
원본 + 잡음 주입	83.3%	0.6859
원본 + 크기 조정	78.7%	0.3379

표 2. 특정 데이터 증강 기법을 제외했을 때의 성능

활용 데이터	F1 score	MSE
전체 - 잡음 주입	90.8%	0.2560
전체 - 크기 조정	88.8%	0.3819
전체 - 자르고 붙이기	85.4%	0.3036
전체 데이터	92.4%	0.2444

표 1 의 실험결과에 따르면 분할 기법을 적용했을 때의 분류 성능이 가장 높은 것을 알 수 있다. 이는 모델이 운동 데이터의 추세를 다양하게 학습할 수 있음을 보여준다. 횟수 예측은 사용자마다 운동을 하는 속도가 상이하여 다양한 템포의 데이터를 학습하는 것이 중요하다. 따라서 크기 조정 기법을 적용하였을 때의 횟수 예측 성능이 좋을 것을 보여준다.

표 2 는 각 증강 기법을 다양하게 적용하고 최종적으로 모든 기법을 적용한 데이터셋을 통해 비교 실험한 결과이다. 각 데이터셋은 30000 개로 증강 기법의 종류에 따라 균일하게 적용하였다. 실험 결과에 따르면 모든 증강 기법을 적용한 수치가 가장 높은 것을 통해 증강 기법을 각각 적용하였을 때 보다 다양한 증강 기법을 사용하였을 때 인공 신경망이 더 원활한 학습을 할 수 있음을 확인할 수 있다.

참 고 문 헌

- [1] Um, Terry T., et al. "Data augmentation of wearable sensor data for parkinson's disease monitoring using convolutional neural networks." Proceedings of the 19th ACM International Conference on Multimodal Interaction. 2017.
- [2] Karim, Fazle, et al. "Multivariate LSTM-FCNs for time series classification." Neural Networks 116 (2019): 237-245.
- [3] Yang, Hye Kyung, and H. S. Yong. "Real-time physical activity recognition using tri-axis accelerometer of smart phone." Journal of Korea Multimedia Society 17.4 (2014): 506-513.
- [4] Wen, Qingsong, et al. "Time series data augmentation for deep learning: A survey." arXiv preprint arXiv:2002.12478 (2020).